讯飞星火大模型 API 封装

01 说明

自ChatGPT火了之后，国内的大模型发展如雨后春笋。

讯飞星火大模型是国内排名靠前的一款，而且官方提供的API调用也比友商大度，

申请通过后直接是四百万个tokens的**免费额度**。

> V1.5 版本的二百万tokrn + V2.0 版本的二百万token。
>
> 官方文档中提到：讯飞的token计算，1tokens 约等于1.5个中文汉字 或者 0.8个英文单词。
>
> 所以总量相当于六百万字的中文文本交互。

但是官方提供的API调用示例太过简陋了，没有错误码与错误信息提示，没有tokens的计算功能，

以体验为主，仅支持多轮会话窗口。

操作起来对新手并不友好。

本项目对其 python版的调用示例 进行封装，以方便编程小白使用。

项目中包含 official_demo 和 spark_api 两个文件夹，前者为官方调用示例（2023-08-24），供学习使用；后者即为封装版。

02 使用示例

```
from spark_gpt import SparkGPT

# 1. 实例化SparkGPT，
#   1.1 实例化时可以选择性传入一个prompt：
#       此处传入的prompt会覆盖配置信息中的prompt；
#       不传入的话，将使用配置文件中提供的prompt；
#       若配置文件未设置prompt，则程序交互时不使用prompt。
#   1.2 实例化时还可以选择性传入language参数，language涉及到文本长度的计算：
#       language == "chinese" ，文本最长可至12000字；
#       language == "english"，文本最长可至6000单词；
#       不传入language参数，默认language == "general"，文本最长可至9000字符。
speaker = SparkGPT("接下来我会给你发送一个文案，请你以伴侣的口吻帮我润色一下，加上合适的称呼", language="chinese")

# 2. 单次询问
answer = speaker.ask("今生今世有缘和你在一起，每一分，每一秒都是幸福，都是老天恩赐的福祉。")
```

```
print(answer)
# 输出示例：
# 亲爱的，我知道我们的相遇是缘分所赐，而能够和你在一起，每一分、每一秒都是我今生今世的幸福。这份幸福，是我一生最珍贵的宝藏。
# 谢谢你为我带来的一切美好，我愿意与你一起，永远珍惜这份恩赐的福祉。

# 3. 多轮对话
speaker.talk()
```

```
from spark_gpt import SparkGPT

# 1. 实例化SparkGPT，
#   1.1 实例化时可以选择性传入一个prompt：
#       此处传入的prompt会覆盖配置信息中的prompt；
#       不传入的话，将使用配置文件中提供的prompt；
#       若配置文件未设置prompt，则程序交互时不使用prompt。
#   1.2 实例化时还可以选择性传入language参数，language涉及到文本长度的计算：
#       language == "chinese" ，文本最长可至12000字；
#       language == "english"，文本最长可至6000单词；
#       不传入language参数，默认language == "general"，文本最长可至9000字符。
speaker = SparkGPT("接下来我会给你发送一个文案，请你以伴侣的口吻帮我润色一下，加上合适的称呼", language="chinese")

# 2. 单次询问
answer = speaker.ask("今生今世有缘和你在一起，每一分，每一秒都是幸福，都是老天恩赐的福祉。")
print(answer)
# 输出示例：
# 亲爱的，我知道我们的相遇是缘分所赐，而能够和你在一起，每一分、每一秒都是我今生今世的幸福。这份幸福，是我一生最珍贵的宝藏。
# 谢谢你为我带来的一切美好，我愿意与你一起，永远珍惜这份恩赐的福祉。

# 3. 多轮对话
speaker.talk()
```

① 导入 SparkGPT类

② 进行实例化，选择性传入prompt和language

③ ask方法，单次询问，返回大模型的回复内容

④ talk方法，开启多轮对话

配置相关：

实例.app_id ： 返回app_id。

实例.api_key ： 返回api_key。

实例.api_secret ： 返回api_secret。

实例.domain ： 返回domain。在目前（2024-08-24）版本中，官方只提供 "generalv1" 和 "generalv2"。

实例.Spark_url ： 返回Spark_url。在目前（2024-08-24）版本中，官方只提供 "ws://spark-api.xf-yun.com/v1.5/chat" 或者 "ws://spark-api.xf-yun.com/v2.1/chat"。

（注意：domain参数需要和Spark_url搭配）

实例.max_tokens ： 返回max_tokens。默认为2048，模型回答的tokens的最大长度，即允许它输出文本的最长字数。

实例.temperature ： 返回temperature。取值为[0,1],默认为0.5。取值越高随机性越强、发散性越高，即相同的问题得到的不同答案的可能性越高。

实例.top_k ： 返回top_k。取值为[1，6],默认为4。从k个候选中随机选择一个（非等概率）

（注意：temperature和top_k都涉及到回答的随机性，官方建议，修改随机性时，修改其中一个即可。）

实例.prompt ： 返回实例的prompt。

实例.text ： 返回列表，存储当前实例的历史会话信息。

实例.all_answers_data ： 返回当前实例所有答案的流式信息。

实例.prompt ： 返回实例的prompt。

---

token计算相关：

实例.this_tokens ： 返回最新一次交互中，消耗的tokens总数

实例.this_answer_tokens ： 返回最新一次交互中，回答部分的tokens数

实例.this_question_tokens ： 返回最新一次交互中，问题部分的tokens数，在多轮会话中，也是累计问题tokens数

实例.all_tokens ： 返回累计消耗tokens总数

方法相关：

实例.set_max_tokens(value) ： 修改当前实例的max_tokens

实例.set_top_k(value) ： 修改当前实例的top_k

实例.set_temperature(value) ： 修改当前实例的temperature

实例.set_language(value) ： 修改当前实例的language，可传入 chinese 或 english ，该值主要涉及输入文本最大长度计算。

实例.reset_text() ： 重置历史会话记录

实例.ask(self, question) ： 接收一个问题，返回sparkGPT的回复。

实例.talk() ： 开启多轮会话。

实例.get_text() ： 返回一个列表，元素为字典。内容为对话记录。

实例.get_answer() ： 返回最新一次交互的答案

02 官方API的申请与使用

2.1 使用前需先配置信息

在config_demo.json中修改 app_id, api_secret, api_key三个值,

然后将 config_demo.json 重命名为 config.json 。

2023-08-28 更新：配置文件中新增了微调参数设置，日志控制设置与错误码信息。

> 在此处修改微调参数，请确保其符合官方文档要求。详见下方【一些参数说明】

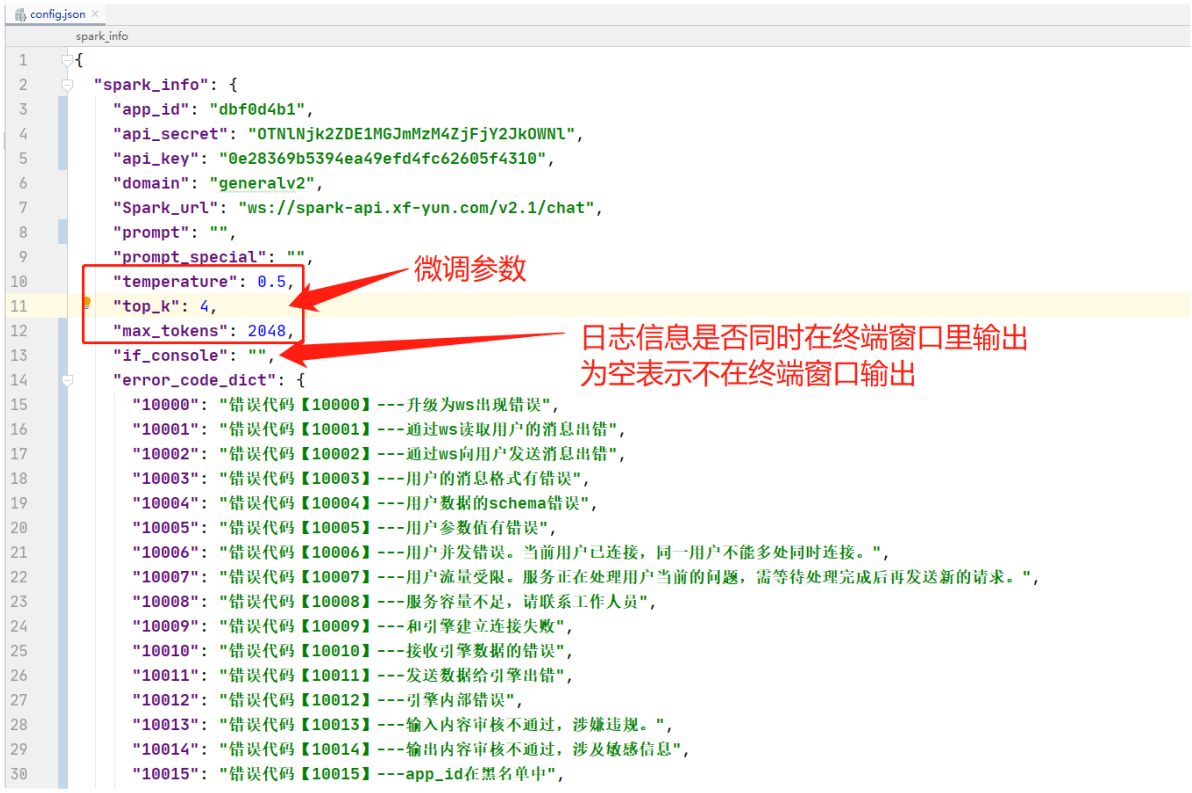


```
{
  "spark_info": {
    "app_id": "dbf0d4b1",
    "api_secret": "OTNlNjk2ZDE1MGJmMzM4ZjFjY2JkOWNl",
    "api_key": "0e28369b5394ea49efd4fc62605f4310",
    "domain": "generalv2",
    "Spark_url": "ws://spark-api.xf-yun.com/v2.1/chat",
    "prompt": "",
    "prompt_special": "",
    "temperature": 0.5,
    "top_k": 4,
    "max_tokens": 2048,
    "if_console": "",
    "error_code_dict": {
      "10000": "错误代码【10000】---升级为ws出现错误",
      "10001": "错误代码【10001】---通过ws读取用户的消息出错",
      "10002": "错误代码【10002】---通过ws向用户发送消息出错",
      "10003": "错误代码【10003】---用户的消息格式有错误",
      "10004": "错误代码【10004】---用户数据的schema错误",
      "10005": "错误代码【10005】---用户参数值有错误",
      "10006": "错误代码【10006】---用户并发错误。当前用户已连接，同一用户不能多处同时连接。",
      "10007": "错误代码【10007】---用户流量受限。服务正在处理用户当前的问题，需等待处理完成后再发送新的请求。",
      "10008": "错误代码【10008】---服务容量不足，请联系工作人员",
      "10009": "错误代码【10009】---和引擎建立连接失败",
      "10010": "错误代码【10010】---接收引擎数据的错误",
      "10011": "错误代码【10011】---发送数据给引擎出错",
      "10012": "错误代码【10012】---引擎内部错误",
      "10013": "错误代码【10013】---输入内容审核不通过，涉嫌违规。",
      "10014": "错误代码【10014】---输出内容审核不通过，涉及敏感信息",
      "10015": "错误代码【10015】---app_id在黑名单中",
```

2.2 配置信息详细步骤

第一步：登录讯飞后台：讯飞星火认知大模型

> 如果没有账号，则需先注册、

第二步：创建一个应用。

第三步：返回首页讯飞星火认知大模型，申请讯飞星火认知大模型的API测试权限。


首页
SparkDesk
API测试
星火助手
星火插件
我是讯飞星火认知大模型
只需一个指令 "懂你所言，答你所问，创你所需，解你所难，学你所教"
有问必答，我是你的讯飞星火_
进入体验
API测试
注册、登录后，
如未申请API测试，则点击【API测试】
星火APP
HOT
随时随地 让海量知识与创意触手可得
星火API
多元能力，快速接入，创建专属AI应用
星火助手
你的智能办公生活助手 让工作生活更简单高效
星火插件
扩展应用场景 满足个性化需求 探索大模型应用边界


讯飞星火认知大模型
新一代认知智能大模型，拥有跨领域知识和语言理解能力，能够基于自然对话方式理解与执行任务
多模交互
代码能力
文本生成
数学能力
内测APP


讯飞开放平台 OPEN PLATFORM
产品能力
行业方案
星火大模型
机器人超脑
服务市场
生态合作
服务支持
AI开发者大赛
中文站
讯飞星火认知大模型能力
Beta测试
以中文为核心的新一代认知智能大模型，拥有跨领域的知识和语言理解能力，能够基于自然对话方式理解与执行任务。持续从海量数据和大规模知识中学习进化，实现从提出问题、规划问题到解决问题的全流程闭环。
API测试申请
应用场景
产品优势
行业应用
开发者测试文档
继续点击 【API测试申请】
< 应用场景 >
语言理解
进行多层次跨语种语言理解，实现要素抽取、语篇归整、情感分析、多语言翻译等
知识问答
可以回答各种各样的问题，包括生活知识、工作技能、医学知识等
逻辑推理
拥有基于思维链的推理能力，能够进行科学、常识等推理
数学能力
具备数学思维，能理解数学问题，覆盖多种题型，并能给出解题步骤
代码理解与编写
可以进行代码理解、代码修改以及代码编写等工作

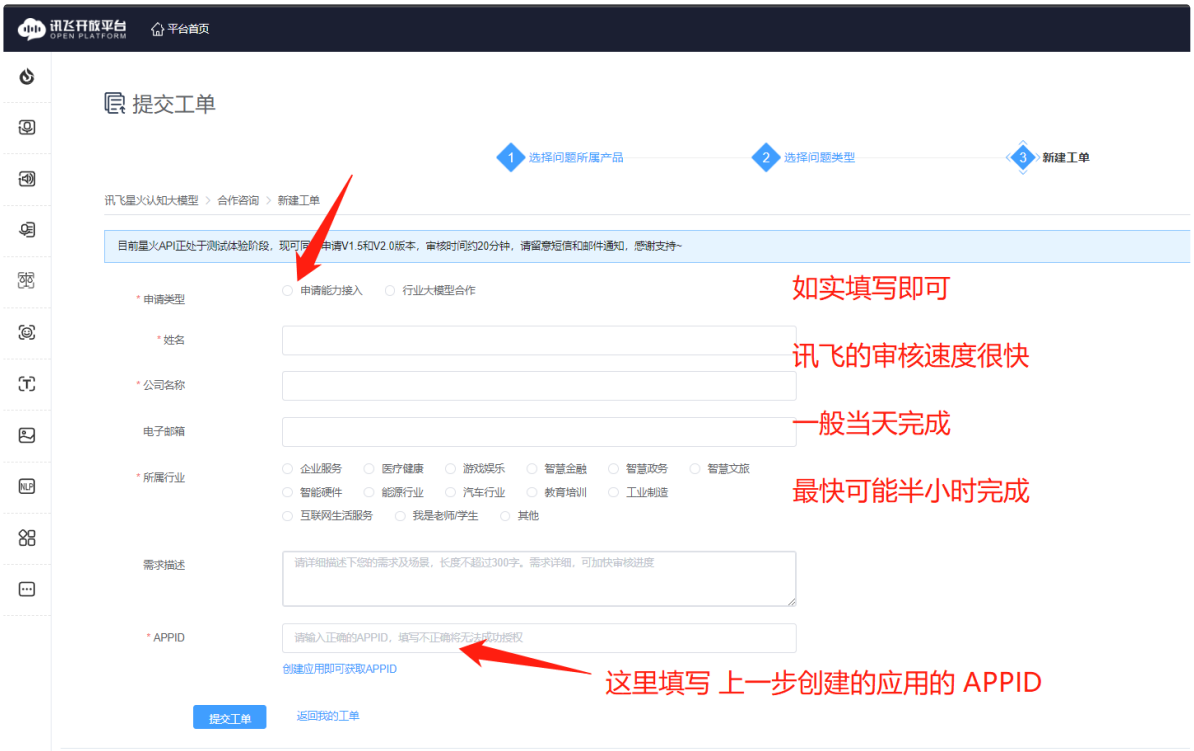

第四步：等待官方通过申请。然后点击 你创建的应用，再点击左侧的【星火认知大模型】

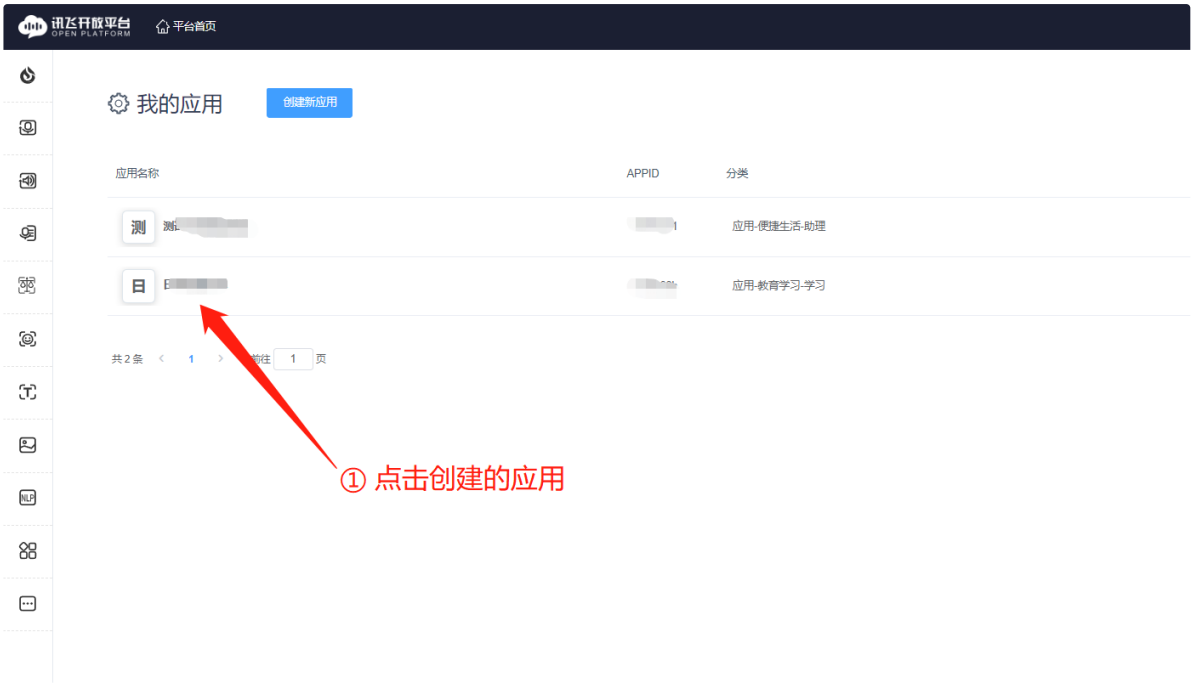

第五步：获取认知三要素，配置文件中的 Spark_url 也在此页获取。

第六步：将获取到的信息填入配置文件中。然后将 config_demo.json 重命名为 config.json 。

2.3 使用步骤

2.3.1 第一步：下载代码

可以拉取GitHub的项目代码。

```
git clone git@github.com:zibuyu2015831/xfyun-spark-api.git
```

也可以从本人的公众号获取。

关注【思维兵工厂】，回复“星火大模型”。有使用问题，也可到公众号与我联系。

（不建议从其他渠道获取，以防有心之人修改了代码，以致泄露信息的情况。）

2.3.2 第二步：安装必要依赖

```
pip install -r requirements
```

其实，只用到了一个第三方包： websocket_client 。用下面的命令也可以：

```
pip install websocket_client
```

(关于websocket_client的版本，官方没作要求。我使用的是1.5.2版本。)

2.3.3 导入使用

（后期可能更新一些使用案例）

03 使用注意

在官方文档的说明中，访问的token需要控制在8192内。

> 而token字符的换算，根据官方给出的数据，1 token = 约等于1.5个中文汉字 或者 0.8个英文单词。

也就是说：

- 单次调用（即上图调用 speaker.ask() 方法），文本最大长度为 **1.2万个中文汉字** 或者 **6千个单词**。
- 多轮会话（即上图调用 speaker.talk() 方法），类似汉字（包括问题与答案）最多1.2万。超过1.2万字将逐渐丢失上下文语境。

04 一些参数说明

微调大模型的输出结果，是通过修改请求头的某些参数实现的。

具体来说，在配置文件 config.json 中，后三个值，可以修改，以微调输出结果。

参数修改请参考官方表格：

参数名称	类型	必传	参数要求	参数说明
domain	string	是	取值为[general,generalv2]	指定访问的领域,general指向V1.5版本 generalv2指向V2版本。注意：不同的取值对应的url也不一样！
temperature	float	否	取值为[0,1],默认为0.5	核采样阈值。用于决定结果随机性，取值越高随机性越强即相同的问题得到的不同答案的可能性越高
max_tokens	int	否	取值为[1,4096]，默认为2048	模型回答的tokens的最大长度
top_k	int	否	取值为[1，6],默认为4	从k个候选中随机选择一个（非等概率）

参数名称	类型	必传	参数要求	参数说明
chat_id	string	否	需要保障用户下的唯一性	用于关联用户会话

注意，在官方早期的demo中，可能会出现 random_threshold参数 和 auditing参数 ，但官方文档(2023-08-24)中并未说明。

经过咨询对方技术人员， auditing参数 为输入输出的审核参数，当前是默认值； random_threshold参数 = temperature 。

详细请参照官方文档： 科大讯飞_(xfyun.cn)官方文档

05 关于tokens消耗的测试

以下是一次多轮会话的tokens消耗数据：

第一次交互：

> 问：请你根据你掌握的历史回答我的问题，如果你不知道就说不知道。秦始皇的真名是什么？
>
> 答：秦始皇的真名是嬴政。

本次问答tokens数： 53
本次问题tokens数： 44
本次答案tokens数： 9

累计问题tokens数： 44
累计消耗tokens数： 53

第二次交互：

> 问：秦始皇出名的儿子都有谁？
>
> 答：秦始皇有十八个儿子，但其中比较出名的只有两位：扶苏和胡亥。扶苏是秦始皇的长子，但其性格温和、仁爱，不似秦始皇那般强势，因此并没有得到秦始皇的宠爱。而胡亥则是秦始皇的小儿子，在秦始皇死后继位，但不久就被赵高等人所杀。

本次问答tokens数： 139
本次问题tokens数： 68
本次答案tokens数： 71

累计问题tokens数： 68
累计消耗tokens数： 192

第三次交互：

> 问：秦始皇死的那天早上，早餐吃了什么？

> 答：关于秦始皇死的那天早上他吃了什么，历史上并没有明确的记载。不过根据一些文献和传说，有几种说法认为他当天早上可能吃了粗粮和蔬菜做的粥，以及蒸鱼、烤肉等食物。但这些都只是猜测，无法确定其真实性。

本次问答tokens数： 212
本次问题tokens数： 156
本次答案tokens数： 56

累计问题tokens数： 156
累计消耗tokens数： 404

第四次交互：

> 问：秦始皇灭六国统一天下，哪一个国家是秦始皇最后消灭的?
>
> 答：秦始皇灭六国统一天下的过程中，最后一个被消灭的国家是韩国。秦始皇先后击败了赵国、魏国、楚国、燕国和齐国，最终只剩下韩国没有被征服。秦始皇派遣王贲率领大军进攻韩国，经过三年的战争，最终于公元前230年攻陷韩国都城新郑，使韩国成为秦国的附属国。随后，秦始皇将韩国的领土划分为三十个郡，设立秦韩两郡，标志着中国历史上第一次大一统王朝—秦朝的建立。

本次问答tokens数： 340
本次问题tokens数： 236
本次答案tokens数： 104

累计问题tokens数： 236
累计消耗tokens数： 744

第五次交互：

> 问：哪一个国家是他最先消灭的?
>
> 答：秦始皇最先消灭的国家是赵国。在秦灭六国的过程中，秦始皇采取了先易后难、各个击破的策略，而赵国是他攻打的第一个国家。公元前230年，秦始皇派遣将军王翦率领大军进攻赵国都城邯郸，经过一年多的战斗，最终于公元前225年攻陷邯郸，使赵国成为秦国的附属国。此后，秦始皇又先后击败了魏国、楚国、燕国和齐国，最终统一天下建立了秦朝。

本次问答tokens数： 455
本次问题tokens数： 356
本次答案tokens数： 99

累计问题tokens数： 356
累计消耗tokens数： 1199

第六次交互：

> 问：替秦始皇征战的将军都有谁?
>
> 答：秦始皇统一天下的过程中，派遣了众多的将领和名将征战四方，其中一些比较出名的将军包括：
>
> 1. 李斯：秦国重要的政治家和谋士，也是秦始皇身边的得力干将，替秦始皇拟定了许多重要的政策和法律。

2．王翦：秦国重要的将领之一，替秦始皇征战六国，先后击败了赵国、魏国等国。
3．蒙恬：秦国重要的将领之一，替秦始皇征战北方，曾多次打败匈奴等外族。
4．章邯：秦国将领，曾替秦始皇攻打赵国，后来在楚汉战争中投降了刘邦。
5．项羽：虽然项羽并非秦始皇时期的将领，但他是秦末时期的重要人物之一，替秦朝东征西讨，最终推翻了秦朝的统治。

本次问答tokens数： 644
本次问题tokens数： 472
本次答案tokens数： 172

累计问题tokens数： 472
累计消耗tokens数： 1843

第七次交互：

> 问：这些将军中，哪一个的历史结局比较好？
>
> 答：这些将军中，历史结局比较好的可能是王翦。王翦替秦始皇征战六国，先后击败了赵国、魏国等国，是秦国的一位重要将领。在秦始皇死后，他的儿子王贲继续为秦朝效力，成为重要的官员和军事将领。而其他一些将军，如蒙恬、章邯等，在秦始皇死后不久就被指控谋反，被迫自杀或被处死。项羽则是在秦末时期崛起的一位将领，虽然他曾经替秦朝东征西讨，但最终却与刘邦结盟，成为了汉朝的开国皇帝。

本次问答tokens数： 780
本次问题tokens数： 662
本次答案tokens数： 118

累计问题tokens数： 662
累计消耗tokens数： 2623

累计消耗tokens：2623

根据官方目前的计费标准（2023-08-24）：

使用v2.0版本费用为：0.83936 元
使用v1.5版本费用为：0.41968 元

结论：

从累计消耗tokens数与大模型底层逻辑来看，大模型其实不适合多轮会话，所谓多轮会话，是将重复输入前面的问题，以便让大模型了解语义。

以上面的例子来说，第七次交互时，是将前六次的问题合并到第七次的问题中，在输入给大模型。

因此，多轮会话的交互次数越多，对tokens的消耗就越快。

从上面可以看到，

第一个问题消耗的tokens数为44，第七个问题的tokens消耗就高达2623，大概是第一个问题的60倍。